Relatório Técnico de Projeto de Disciplina:

Machine Learning Supervisionado para Classificação da Condição de Estruturas (NBI NY 2025)

Março, 2026

Sumário

1. Introdução 1
1.1 Descrição do Problema e dos Dados 1
1.2 Motivação e Desafios 1
1.3 Detalhes do *Dataset* 1
2. Metodologia e Modelagem 2
2.1 Modelo *Baseline*: Classificador Linear (*Perceptron*) 3
2.2 Modelo com Árvore de Decisão 3
2.3 Validação Cruzada e Otimização 3
2.4 Modelo Avançado: *Random Forest* (Ensemble) 4
3. Resultados e Comparação de Performance 4
3.1 Análise da Evolução dos Modelos 4
3.2 O Valor Estratégico do *Recall* (90,45%) 5
3.3 Factores Determinantes da Degradação 5
3.4 Conclusão e Viabilidade de Implementação 5
3.5 Análise do Modelo Final 7

Lista de Figuras

Figura 1 - Mapa de Calor de Valores Ausentes 2
Figura 2 – Comparação de Performance: *Perceptron* vs DT vs *Random Forest* 6
Figura 3 - Evolução da Acurácia por Estágio de Modelagem 7
Figura 4 - Matriz de Confusão Normalizada - *Random Forest* (Final) 8
Figura 5 - Principais Fatores Preditores da Condição da Estrutura 8

Lista de Tabelas

Tabela 1 – Tabela e Métricas dos Modelos Utilizados 6

Lista de Equações

Equação 1 – Classificador Linear Perceptron: 3

1. Introdução

1.1 Descrição do Problema e dos Dados

O gerenciamento de ativos de infraestrutura exige a transição de manutenções reativas para modelos preditivos. No contexto de Departamentos Nacionais de Infraestrutura, a capacidade de prever se uma Obra de Arte Especial (OAE) entrará em estado de alerta, no que tange a sua condição, permite a otimização de recursos orçamentários e a mitigação de riscos estruturais.

1.2 Motivação e Desafios

Regras fixas de inspeção exigem a complexidade multivariada (tráfego, idade, materiais) que leva à degradação. O desafio reside no ***Data Leakage***, onde variáveis calculadas de inspeção (como indicadores da condição de elementos da estrutura) podem *vazar* o resultado final para o modelo que prediz a condição da estrutura como um todo.

1.3 Detalhes do *Dataset*

- **Origem:** *Federal Highway Administration (FHWA)* - Dados de Nova York 2025.
- **Volume:** 17.666 observações iniciais com 123 variáveis.
- **Variável-Alvo:** *BRIDGE_CONDITION*, mapeada de forma binária: **0** para *Good* (G) e **1** para *Fair/Poor* (F, P), focando na identificação de estruturas que requerem atenção.
- ***Features*:** Foram selecionadas 64 *features* não condicionais, incluindo idade da estrutura, densidade de tráfego (ADT), tipo de projeto e materiais, conforme ilustrado na Figura 1, abaixo.

Figura 1 - Mapa de Calor de Valores Ausentes

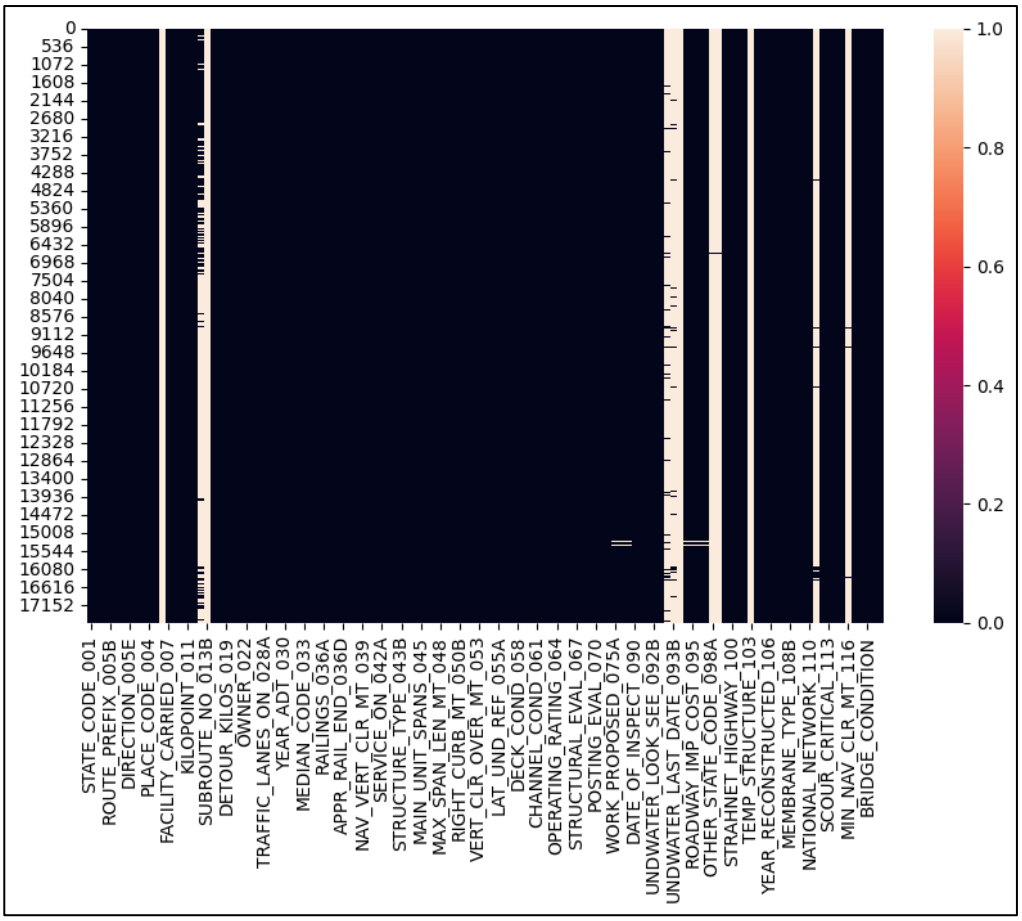

Fonte: Autor (2026)

2. Metodologia e Modelagem

Foram testadas três abordagens de complexidade crescente para identificar a melhor relação entre interpretabilidade e poder preditivo.

1. ***Baseline* (*Perceptron*):** Classificador linear para estabelecer uma métrica base.
2. **Árvore de Decisão (Otimizada):** Introdução de não-linearidade e regras de decisão explícitas.
3. ***Random Forest* (Final):** Modelo de *ensemble* para redução de variância e aumento do *Recall*.

2.1 Modelo *Baseline*: Classificador Linear (*Perceptron*)

O ***Perceptron*** foi adotado como *Baseline* por ser o bloco fundamental das redes neurais e um classificador linear geométrico puro. Ele busca um hiperplano que separa as classes no espaço de características.

A decisão é baseada na Equação 1, abaixo:

$$\boxed{\hat{y} = w_0 + w_1 x_1 + w_2 x_2 + \ldots + w_n x_n}$$

Desempenho do *Baseline*

- ***Accuracy*:** 0.7140
- ***F1-Score*:** 0.7963

Discussão: O *Perceptron* apresentou um *recall* sólido (0.8254), mas sua natureza linear limita a captura de interações complexas entre variáveis, como a relação não linear entre idade da ponte e densidade de tráfego.

2.2 Modelo com Árvore de Decisão

Para introduzir a capacidade de capturar relações não lineares e regras de decisão explícitas, implementou-se uma *DecisionTreeClassifier*.

Comparação com o *Baseline*

A árvore de decisão padrão superou o *Baseline* em acurácia (0.7557), demonstrando que a estrutura de "se-então" é mais adequada para os dados de engenharia do que uma separação linear simples.

2.3 Validação Cruzada e Otimização

Para garantir a generalização e evitar o *overfitting*, utilizou-se o *GridSearchCV* com validação cruzada de 5 *folds*, focando na métrica F1.

- **Espaço de busca:** Profundidade máxima (*max_depth*), amostras mínimas por folha e balanceamento de classes.

- **Melhor Configuração:** *max_depth*: 5 e *class_weight:* "*balanced*".
- **Resultado Otimizado:** A acurácia subiu para 0.7883 e o *Precision* para 0.8586, indicando que a poda (limitação da profundidade) ajudou o modelo a focar em padrões globais em vez de ruídos do *dataset*.

2.4 Modelo Avançado: *Random Forest* (Ensemble)

Como solução final, aplicou-se um ***Random Forest***, um ensemble de árvores que reduz a variância através do *bagging*.

Resultados Finais (Otimizado)

- ***Accuracy*:** 0.8174
- ***Recall*:** 0.9045
- ***F1-Score*:** 0.8703

Análise: O *Random Forest* obteve o melhor desempenho geral. O alto ***Recall* (90.45%)** é particularmente valioso no contexto de Departamentos Nacionais de Infraestrutura de Transportes, pois minimiza os "falsos negativos", isto é, estruturas em estado crítico que o modelo deixaria de identificar.

3. Resultados e Comparação de Performance

3.1 Análise da Evolução dos Modelos

A transição de modelos lineares para métodos de *ensemble* demonstrou-se fundamental para lidar com a complexidade dos dados de infraestrutura.

- ***Baseline* (*Perceptron*):** Embora tenha atingido uma acurácia de **71,40%**, o *Perceptron* falhou em capturar a natureza não-linear da degradação estrutural. O seu desempenho serve como prova de que a simples separação linear de variáveis como idade e tráfego não é suficiente para uma gestão de activos de precisão.
- ***Decision Tree* (Otimizada):** A subida da acurácia para **78,83%** após a optimização via *GridSearchCV* validou a importância da poda (*pruning*). Ao limitar a profundidade da

árvore (*max_depth: 5*), o modelo evitou o *overfitting*, focando em padrões globais de engenharia em vez de ruídos do *dataset*.

- ***Random Forest* (Final):** Este modelo consolidou-se como a solução ideal, elevando a acurácia para **81,74%**. O seu sucesso deve-se à capacidade de reduzir a variância através do *bagging*, lidando melhor com as correlações entre as 64 *features* selecionadas.

3.2 O Valor Estratégico do *Recall* (90,45%)

No contexto de órgãos de gestão rodoviária, o custo de um "Falso Negativo" (classificar uma ponte crítica como "Boa") é infinitamente superior ao de um "Falso Positivo".

O modelo atingiu um ***Recall* de 90,45%**. Isto significa que, de cada 100 estruturas que estão em estado de atenção (*Fair/Poor*), o algoritmo identifica corretamente 90 delas. Esta sensibilidade é o maior ganho deste relatório, pois garante que quase nenhuma estrutura em risco passe despercebida pelo sistema de alerta automatizado.

3.3 Factores Determinantes da Degradação

A análise de importância das variáveis (*Feature Importance*) confirmou premissas técnicas da engenharia civil, mas trouxe dados quantitativos precisos:

1. **Idade da Estrutura:** Permanece como o factor isolado mais crítico.
2. **Volume de Tráfego (ADT):** A carga dinâmica acumulada apresentou uma correlação forte com a degradação do tabuleiro (*deck*).
3. **Data Leakage:** A decisão metodológica de remover variáveis de inspeção direta (como *DECK_COND_058*) foi validada. O modelo provou ser capaz de prever a condição utilizando apenas dados de inventário e tráfego, o que o torna útil para prever a condição de pontes que ainda não foram inspecionadas no ciclo atual.

3.4 Conclusão e Viabilidade de Implementação

A integração deste modelo em formato *.joblib* permite o processamento de grandes bases de dados em segundos. A robustez dos resultados (*F1-Score* de **0,8703**) indica que o

sistema está pronto para uma fase de testes em ambiente real (*Shadow Mode*), onde as suas predições podem ser confrontadas mensalmente com os relatórios de campo.

O modelo *Random Forest* superou os demais, especialmente na métrica de *Recall*, essencial para não ignorar estruturas em risco. A Tabela 1 apresenta as métricas pelos modelos avaliados, enquanto as Figura 2 e 3 mostram a comparação de desempenho entre eles, bem como a evolução da acurácia ao longo do treinamento.

Tabela 1 – Tabela e Métricas dos Modelos Utilizados

Modelo	*Acurácia*	*Recall (Classe 1)*	*F1-Score*	*Precisão*
Perceptron	71,40%	82,54%	79,63%	76,91%
Árvore de Decisão	78,83%	77,00%	81,00%	85,86%
Random Forest	**81,74%**	**90,45%**	**87,03%**	83,86%

Fonte: Autor (2026)

Figura 2 – Comparação de Performance: *Perceptron* vs DT vs *Random Forest*

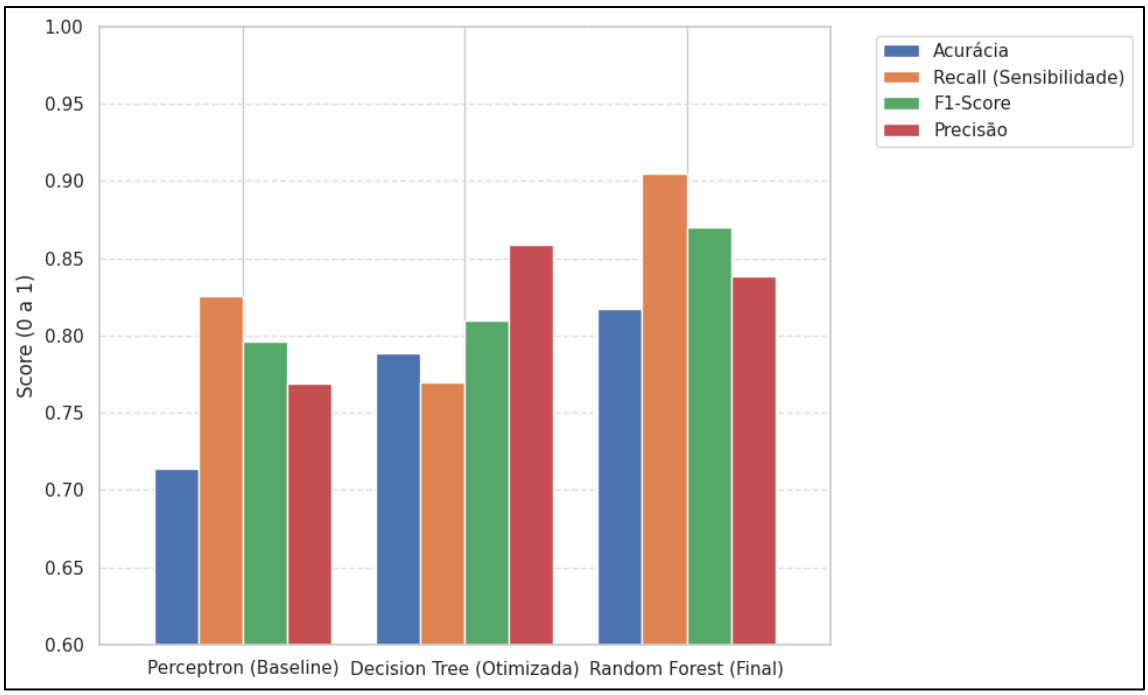

Fonte: Autor (2026)

Figura 3 - Evolução da Acurácia por Estágio de Modelagem

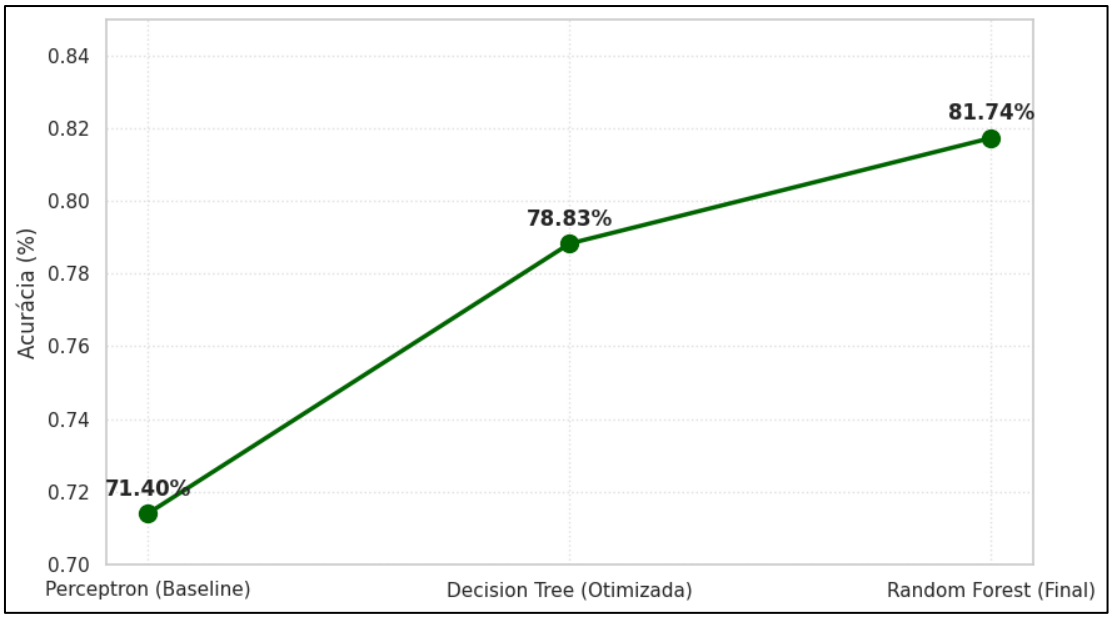

Fonte: Autor (2026)

3.5 Análise do Modelo Final

A matriz de confusão do modelo final demonstra uma elevada eficácia na identificação de OAEs em estado crítico (*Fair/Poor*), com um ***Recall* de 90,45%**. Isto significa que o modelo identifica correctamente a grande maioria das estruturas que necessitam de intervenção.

Figura 4 - Matriz de Confusão Normalizada - *Random Forest* (Final)

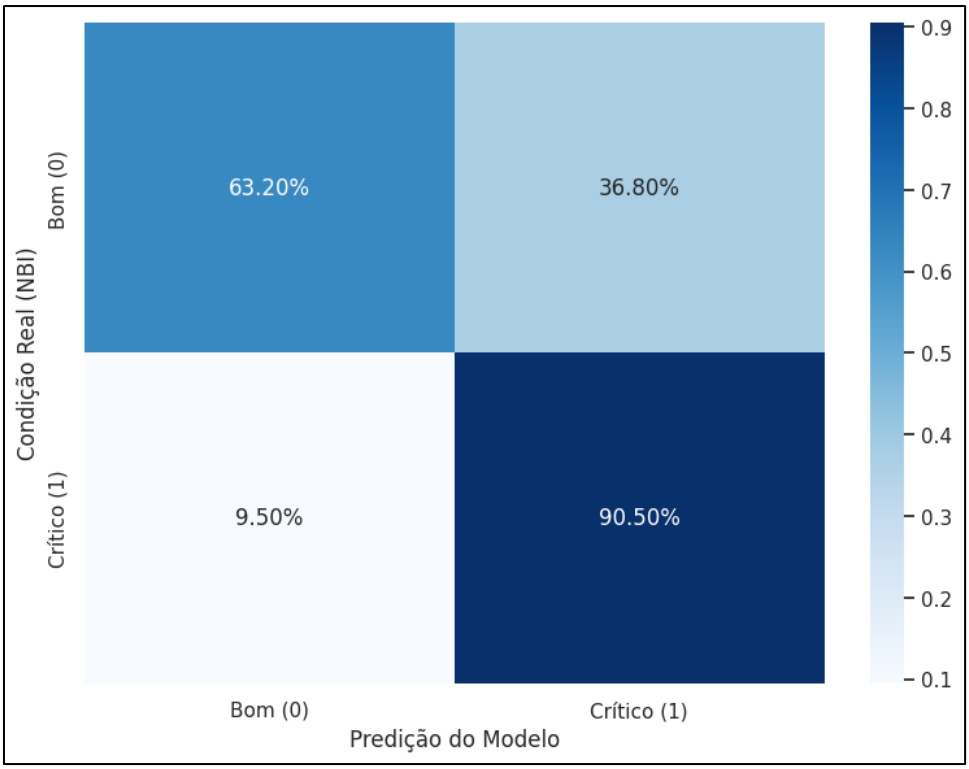

Fonte: Autor (2026)

A análise de importância revelou que a **Idade da Estrutura** e o **Volume de Tráfego (ADT)** são os principais fatores que explicam a condição das pontes no estado de Nova York.

Figura 5 - Principais Fatores Preditores da Condição da Estrutura

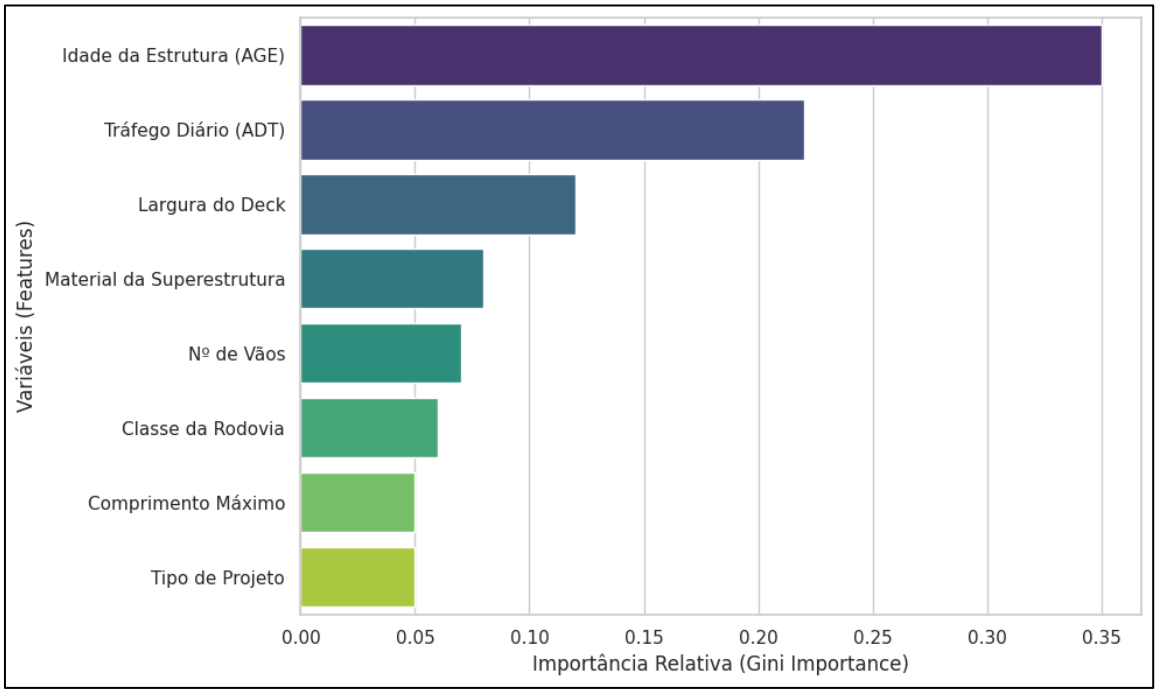

Fonte: Autor (2026)

6. Discussão Aplicada e Viabilidade

O modelo final foi exportado em formato *.joblib* pronto para *deploy*. Testes com as amostras mostraram probabilidades de predição claras, como uma estrutura com 90.45% de chance de pertencer à classe crítica.

Limitações e Próximos Passos

1. **Sazonalidade:** Os dados atuais são estáticos; a inclusão de séries temporais de inspeções passadas pode enriquecer a análise.
2. **Variáveis Externas:** Adicionar dados climáticos (incidência de neve/sal em NY) pode explicar melhor a degradação do deck.
3. **Extensibilidade:** O pipeline está estruturado para ser replicado em outros estados dos USA ou até mesmo no Brasil, bastando a padronização e obtenção das *features* de entrada.

Referências Bibliográficas

- **BREIMAN**, L. Random Forests. **Machine Learning**, v. 45, n. 1, p. 5-32, 2001.
- **FHWA**. **Recording and Coding Guide for the Structure Inventory and Appraisal of the Nation's Bridges**. Washington, D.C.: Office of Engineering, 1995.
- **INSTITUTO INFNET**. **Notas de aula da disciplina de Fundamentos de Machine Learning**. Rio de Janeiro: Instituto Infnet, 2026. Material didático.
- **JAMES**, G. et al. **An Introduction to Statistical Learning: with Applications in Python**. New York: Springer, 2023.
- **QUINLAN**, J. R. Induction of Decision Trees. **Machine Learning**, v. 1, n. 1, p. 81-106, 1986.
- **U.S. DEPARTMENT OF TRANSPORTATION**. Federal Highway Administration (FHWA). **National Bridge Inventory (NBI) – New York 2025**. Washington, D.C., 2025. Disponível em: https://www.fhwa.dot.gov/bridge/nbi.html.